



Bone Deformity Detection From X-Ray Images

Members

Sara Naziri



Taha Asqari



Peyman Afshari



CE.Guilan

مقدمه

در این برنامه هدف ما بررسی و شناسایی وجود یا عدم وجود ناهنجاری های موجود در عکس استخوان بازو با استفاده از مدل Inception V 3(Binary_Classification) میباشد. ما با استفاده از این مدل به دقت ۷۹.۸٪ رسیدیم.

ما با استفاده از داده های موجود در دیتاست مورا که توسط دانشگاه استنفورد جمع آوری شده شروع به یادگیری از تصاویر کرده سپس با استفاده از این یادگیری به بررسی و شناسایی ناهنجاری های موجود در تصاویر دیگر میکنیم.

MURA: Large Dataset for Abnormality Detection in Musculoskeletal Radiographs

- We introduce MURA, a large dataset of musculoskeletal radiographs containing 40,561 images from 14,863 studies, where each study is manually labeled by radiologists as either normal or abnormal. To evaluate models robustly and to get an estimate of radiologist performance, we collect additional labels from six board-certified Stanford radiologists on the test set, consisting of 207 musculoskeletal studies. On this test set, the majority vote of a group of three radiologists serves as gold standard. We train a 169-layer DenseNet baseline model to detect and localize abnormalities. Our model achieves an AUROC of 0.929, with an operating point of 0.815 sensitivity and 0.887 specificity. We compare our model and radiologists on the Cohen's kappa statistic, which expresses the agreement of our model and of each radiologist with the gold standard. Model performance is comparable to the best radiologist performance in detecting abnormalities on finger and wrist studies. However, model performance is lower than best radiologist performance in detecting abnormalities on elbow, forearm, hand, humerus, and shoulder studies. We believe that the task is a good challenge for future research. To encourage advances, we have made our dataset freely available at <https://stanfordmlgroup.github.io/competitions/mura/>

مرحله اول

دریافت اجازه دسترسی به گوگل درایو



```
from google.colab import drive  
drive.mount('/content/gdrive')
```



Go to this URL in a browser: <https://accounts.google.com/o/oauth2/auth?client>

Enter your authorization code:

.....

Mounted at /content/gdrive

مرحله دوم

فیل کردن دیتا از Kaggle روی Google Colab



```
!kaggle datasets download -d cjinny/mura-v11
```



Downloading mura-v11.zip to /content/gdrive/My Drive/Kaggle

100% 3.14G/3.14G [00:55<00:00, 39.1MB/s]

100% 3.14G/3.14G [00:56<00:00, 59.5MB/s]



```
%cd /content/gdrive/My Drive/Kaggle  
!pwd  
!ls
```



```
/content/gdrive/My Drive/Kaggle  
/content/gdrive/My Drive/Kaggle  
kaggle.json
```

!pwd : چک کردن بودن در مسیر وارد شده (تایید صحت شناسایی پوشه)
!ls : نشان دادن محتویات پوشه وارد شده

مرحله سوم

Unzipping

شروع به استخراج داده های موجود (تصاویر) از فایل زیپ در داخل پوشه kaggle میکنیم (این پروسه زمان بر است)



```
!unzip *.zip  
# !unzip *.zip && rm *.zip
```



Streaming output truncated to the last 5000 lines.

```
inflating: MURA-v1.1/train/XR_WRIST/patient08489/study1_negative/image4.png  
inflating: MURA-v1.1/train/XR_WRIST/patient08490/study1_negative/image1.png  
inflating: MURA-v1.1/train/XR_WRIST/patient08490/study1_negative/image2.png  
inflating: MURA-v1.1/train/XR_WRIST/patient08490/study1_negative/image3.png  
inflating: MURA-v1.1/train/XR_WRIST/patient08491/study1_negative/image1.png  
inflating: MURA-v1.1/train/XR_WRIST/patient08491/study1_negative/image2.png  
inflating: MURA-v1.1/train/XR_WRIST/patient08492/study1_negative/image1.png
```


مرحله چهارم

استفاده از Cross با بکند tensorflow

وارد کردن کتابخانه های مورد نیاز برای برنامه



```
##### IMPORTs #####  
import cv2  
import numpy as np  
import tensorflow as tf  
import tensorflow_hub as hub  
import tensorflow_datasets as tfds  
import os, glob, shutil  
from tqdm.notebook import tqdm  
from tensorflow.keras.preprocessing.image import ImageDataGenerator  
from PIL import Image
```

مرحله پنجم

پیش پردازش دیتا (دیتا را براساس مدلی که باید بخواند پیش پردازش میکنیم)
مورا شامل هفت دسته است و ما از دسته استخوان بازو استفاده کردیم چرا که دسته کوچکتری نسبت به بقیه است و سرعت انجام عملیات بالاتر است. همچنین میتوانیم دیگر دسته ها را نیز اضافه کنیم.

```
▶ train_files = glob.glob("/content/gdrive/My Drive/Kaggle/MURA-v1.1/train/XR_HUMERUS/**/**/*.png")  
valid_files = glob.glob("/content/gdrive/My Drive/Kaggle/MURA-v1.1/valid/XR_HUMERUS/**/**/*.png")  
print(len(train_files))  
print(len(valid_files))
```



1272



Train_Files

288



Valid_Files



```
# !rm -rf ./prep  
# !ls ./prep
```

Train ها را داخل این پوشه میریزیم.
از این دو دستور زمانی استفاده میکنیم که دچار کرش بشویم و به جای اینکه از اول شروع
شود به اینجا می آییم.
دستور `rm -rf ./prep` را زمانی اجرا میکنیم که دیتا آسیب ببیند و بخواهیم پوشه `prep` را
پاک کنیم.

مرحله ششم

ریختن دیتا داخل پوشه prep

دو پوشه با نام train, valid میسازد (train_folder: های یادگیری شبکه , valid_folder: برای valid کردن شبکه استفاده میشود)

که هر کدام شامل دو پوشه positive, negative میشوند. (positive نشان وجود ناهنجاری, negative عدم وجود ناهنجاری)

```
### Creat preprocessing folder for train ###  
if os.path.isdir('./prep/train/negative/'):  
    pass  
else:  
    os.makedirs('./prep/train/negative/')  
    os.makedirs('./prep/train/positive/')  
!ls  
!pwd
```

```
prep          train_labeled_studies.csv  valid_labeled_studies.csv  
train         valid  
train_image_paths.csv  valid_image_paths.csv  
/content/gdrive/My Drive/Kaggle/MURA-v1.1
```

```
#####preprocssing data###
neg_c = 0
pos_c = 0
for file_name in tqdm(train_files, total=len(train_files)):
    label = file_name.split('/')[-2]
    if "negative" in label:
        shutil.copy(file_name, f'./prep/train/negative/image_{str(neg_c)}.png')
        neg_c += 1
    elif "positive" in label:
        shutil.copy(file_name, f'./prep/train/positive/image_{str(pos_c)}.png')
        pos_c += 1
```

100% 1272/1272 [12:23<00:00, 1.71it/s]

در اینجا برای جلوگیری از مشکل تشابه فایل ها خودمان به آنها شماره ای به اسم
neg-c و pos_c اضافه می کنیم.
هم برای Train_Files و هم برای Valid_Files این کار را میکنیم.



```
!pwd  
!ls /content/gdrive/My\ Drive/Kaggle/MURA-v1.1/prep/train
```



```
/content/gdrive/My Drive/Kaggle/MURA-v1.1  
negative positive
```

این سلول برای حاصل شدن اطمینان از وجود مسیر درست فایل ها است.

مرحله هفتم

مسیر دهی برای شروع آموزش (train)

در لاین آخر عددهای پرینت شده را که در سلول بالا بخش پیدا کردن تعداد آدرس بود، به متغیرها وارد می کنیم.



```
train_dir = "/content/gdrive/My Drive/Kaggle/MURA-v1.1/prep/train/"
valid_dir = "/content/gdrive/My Drive/Kaggle/MURA-v1.1/prep/valid/"
train_pos = "/content/gdrive/My Drive/Kaggle/MURA-v1.1/prep/train/positive/"
train_neg = "/content/gdrive/My Drive/Kaggle/MURA-v1.1/prep/train/negative/"
val_pos = "/content/gdrive/My Drive/Kaggle/MURA-v1.1/prep/valid/positive/"
val_neg = "/content/gdrive/My Drive/Kaggle/MURA-v1.1/prep/valid/negative/"
total_train, total_val = (1272), (288)
```


Total_valid, Total_train: **کل مقادیر** positive, negative **است.**

در مدل ما مقادیر positive **مهم است** (وجود ناهنجاری ها).

در این سلول جزئیات تعداد تصاویر را در پایین سلول وجود دارد.

مرحله هشتم

تنظیم پارامترهای اصلی



```
IMG_SIZE = 150  
batch_size = 16  
epochs = 30
```

در اینجا مقادیر به دست آمده از پوشه های train,valid را پرینت میکنیم. (این بخش صرفاً جهت زیبایی و دریافت مقادیر فایل ها است و تاثیری در روند برنامه ندارد (از بخش های اصلی برنامه نیست))



```
print(f"train positive images: {len(os.listdir(train_pos))}")  
print(f"train negative images: {len(os.listdir(train_neg))}")  
print(f"valid positive images: {len(os.listdir(val_pos))}")  
print(f"valid negative images: {len(os.listdir(val_neg))}")
```



```
train positive images: 599  
train negative images: 673  
valid positive images: 140  
valid negative images: 148
```

تصاویر را به 150×150 پیکسل تبدیل میکنیم. با آزمون و خطا بهترین بازدهی را داد.

Bach_saze : مدل ها را دسته بندی میکند. مرتبط با کارت گرافیک است که با آزمون و خطا به دست می آید. (در اینجا ما از گرافیک RTX 2080 استفاده کردیم)

Epotchs : تعداد مرور دسته ها (چندین بار اجرا شد و بهترین بازده را در ۳۰ داشت)

مقدار train , valid باید نزدیک به هم باشد. اگر valid بزرگتر باشد مشکلی ندارد و جا دارد برای یادگیری بیشتر ولی اگر train بزرگتر باشد دچار مشکل میشویم.

مرحله نهم

نرمال سازی دیتا (Data Normalization)



```
train_generator = ImageDataGenerator(rescale=1./255)  
valid_generator = ImageDataGenerator(rescale=1./255)
```

مرحله دهم

آماده سازی train,valid از روی متغیرها



```
train_data_gen = train_generator.flow_from_directory(  
    batch_size=batch_size, directory=train_dir, shuffle=True,  
    target_size=(IMG_SIZE, IMG_SIZE),class_mode = 'binary'  
)
```



```
Found 1272 images belonging to 2 classes.
```



```
val_data_gen = valid_generator.flow_from_directory(  
    batch_size=batch_size, directory=valid_dir, shuffle=True,  
    target_size=(IMG_SIZE, IMG_SIZE), class_mode = 'binary'  
)
```



Found 288 images belonging to 2 classes.

مرحله یازدهم

مدل اصلی را از آدرس (لینک) زیردانلود و استفاده میکنیم
میتوان از مدل های دیگر نیز استفاده کرد

```
module_url = 'https://tfhub.dev/google/imagenet/inception\_v3/classification/4'
```

مرحله دوازدهم

مقدار اصلی مدل ها را تعریف میکنیم

```
▶ model = tf.keras.Sequential([  
    hub.KerasLayer(module_url,  
                    input_shape=(IMG_SIZE, IMG_SIZE, 3), trainable=False),  
    tf.keras.layers.Dropout(rate=0.3),  
    tf.keras.layers.Dense(1, activation='sigmoid',  
                           kernel_regularizer=tf.keras.regularizers.l2(0.0001))  
])
```



```
model.summary()
```



```
Model: "sequential"
```

Layer (type)	Output Shape	Param #
keras_layer (KerasLayer)	(None, 1001)	23853833
dropout (Dropout)	(None, 1001)	0
dense (Dense)	(None, 1)	1002
Total params: 23,854,835		
Trainable params: 1,002		
Non-trainable params: 23,853,833		

نشان دهنده خلاصه ای از پارامترهای مدل است.

مرحله سیزدهم

بخش train (مقادیر اصلی را که در بالا تنظیم کردیم ، استفاده میکنیم و شروع به train میکنیم. (بخش اصلی پروژه است و زمان زیادی برای اجرا وقت میبرد)

```
history = model.fit_generator(  
    train_data_gen,  
    steps_per_epoch=total_train // batch_size,  
    epochs=epochs,  
    validation_data=val_data_gen,  
    validation_steps=total_val // batch_size,  
)
```

Epoch 1/30	79/79	[=====]	- 15s 191ms/step	- loss: 1.5493	- accuracy: 0.5334	- val_loss: 0.6634	- val_accuracy: 0.7257
Epoch 2/30	79/79	[=====]	- 11s 136ms/step	- loss: 1.0504	- accuracy: 0.6330	- val_loss: 0.7101	- val_accuracy: 0.7049
Epoch 3/30	79/79	[=====]	- 11s 133ms/step	- loss: 1.0333	- accuracy: 0.6218	- val_loss: 0.5309	- val_accuracy: 0.7431
Epoch 4/30	79/79	[=====]	- 11s 138ms/step	- loss: 0.8643	- accuracy: 0.6688	- val_loss: 0.5237	- val_accuracy: 0.7535
Epoch 5/30	79/79	[=====]	- 11s 136ms/step	- loss: 0.7979	- accuracy: 0.6975	- val_loss: 0.4982	- val_accuracy: 0.7986
Epoch 6/30	79/79	[=====]	- 11s 137ms/step	- loss: 0.7674	- accuracy: 0.6990	- val_loss: 0.4751	- val_accuracy: 0.7847
Epoch 7/30	79/79	[=====]	- 11s 139ms/step	- loss: 0.7280	- accuracy: 0.7062	- val_loss: 0.4770	- val_accuracy: 0.7882
Epoch 8/30	79/79	[=====]	- 11s 143ms/step	- loss: 0.7099	- accuracy: 0.7014	- val_loss: 0.4783	- val_accuracy: 0.7812
Epoch 9/30	79/79	[=====]	- 14s 178ms/step	- loss: 0.7093	- accuracy: 0.7014	- val_loss: 0.5528	- val_accuracy: 0.7778
Epoch 10/30	79/79	[=====]	- 11s 136ms/step	- loss: 0.6554	- accuracy: 0.7269	- val_loss: 0.5312	- val_accuracy: 0.7431
Epoch 11/30	79/79	[=====]	- 11s 136ms/step	- loss: 0.6497	- accuracy: 0.7404	- val_loss: 0.4922	- val_accuracy: 0.7812
Epoch 12/30	79/79	[=====]	- 11s 141ms/step	- loss: 0.6442	- accuracy: 0.7365	- val_loss: 0.5409	- val_accuracy: 0.7743
Epoch 13/30	79/79	[=====]	- 11s 137ms/step	- loss: 0.6380	- accuracy: 0.7182	- val_loss: 0.5077	- val_accuracy: 0.7639
Epoch 14/30							

WARNING:tensorflow:From <ipython-input-24-0bb76eff41f2>:6: Model.fit_generator (from tensorflow.python.keras.engine.training) is deprecated and will be removed in a future version.

Instructions for updating:

Please use Model.fit, which supports generators.

Epoch 1/30

79/79 [=====] - 15s 101ms/step - loss: 1.5493 - accuracy: 0.5334 - val_loss: 0.6634 - val_accuracy: 0.7257

Epoch 2/30

79/79 [=====] - 11s 136ms/step - loss: 1.0504 - accuracy: 0.6330 - val_loss: 0.7101 - val_accuracy: 0.7049

Epoch 3/30

79/79 [=====] - 11s 133ms/step - loss: 1.0333 - accuracy: 0.6218 - val_loss: 0.5309 - val_accuracy: 0.7431

Epoch 4/30

79/79 [=====] - 11s 138ms/step - loss: 0.8643 - accuracy: 0.6688 - val_loss: 0.5237 - val_accuracy: 0.7535

Epoch 5/30

79/79 [=====] - 11s 136ms/step - loss: 0.7979 - accuracy: 0.6975 - val_loss: 0.4982 - val_accuracy: 0.7986

Epoch 6/30

79/79 [=====] - 11s 137ms/step - loss: 0.7674 - accuracy: 0.6990 - val_loss: 0.4751 - val_accuracy: 0.7847

Epoch 7/30

79/79 [=====] - 11s 139ms/step - loss: 0.7280 - accuracy: 0.7062 - val_loss: 0.4770 - val_accuracy: 0.7882

Epoch 8/30

79/79 [=====] - 11s 143ms/step - loss: 0.7099 - accuracy: 0.7014 - val_loss: 0.4783 - val_accuracy: 0.7812

Epoch 9/30

79/79 [=====] - 14s 178ms/step - loss: 0.7093 - accuracy: 0.7014 - val_loss: 0.5528 - val_accuracy: 0.7778

Epoch 10/30

79/79 [=====] - 11s 136ms/step - loss: 0.6554 - accuracy: 0.7269 - val_loss: 0.5312 - val_accuracy: 0.7431

Epoch 11/30

79/79 [=====] - 11s 136ms/step - loss: 0.6497 - accuracy: 0.7404 - val_loss: 0.4922 - val_accuracy: 0.7812

Epoch 12/30

79/79 [=====] - 11s 141ms/step - loss: 0.6442 - accuracy: 0.7305 - val_loss: 0.5409 - val_accuracy: 0.7743

Epoch 13/30

79/79 [=====] - 11s 137ms/step - loss: 0.6380 - accuracy: 0.7182 - val_loss: 0.5077 - val_accuracy: 0.7639

Epoch 14/30

79/79 [=====] - 11s 137ms/step - loss: 0.5882 - accuracy: 0.7428 - val_loss: 0.5048 - val_accuracy: 0.7778

Epoch 15/30

79/79 [=====] - 11s 140ms/step - loss: 0.5963 - accuracy: 0.7412 - val_loss: 0.5414 - val_accuracy: 0.7604

Epoch 16/30

79/79 [=====] - 11s 136ms/step - loss: 0.5623 - accuracy: 0.7524 - val_loss: 0.5556 - val_accuracy: 0.7708

Epoch 17/30

79/79 [=====] - 13s 167ms/step - loss: 0.5621 - accuracy: 0.7436 - val_loss: 0.5017 - val_accuracy: 0.7743

Epoch 18/30

79/79 [=====] - 11s 136ms/step - loss: 0.5475 - accuracy: 0.7516 - val_loss: 0.5385 - val_accuracy: 0.7326

Epoch 19/30

79/79 [=====] - 11s 138ms/step - loss: 0.5999 - accuracy: 0.7492 - val_loss: 0.5413 - val_accuracy: 0.7674

Epoch 20/30

79/79 [=====] - 11s 142ms/step - loss: 0.5449 - accuracy: 0.7436 - val_loss: 0.5148 - val_accuracy: 0.7778

Epoch 21/30

79/79 [=====] - 11s 138ms/step - loss: 0.5822 - accuracy: 0.7373 - val_loss: 0.5204 - val_accuracy: 0.7674

Epoch 22/30

79/79 [=====] - 11s 141ms/step - loss: 0.5349 - accuracy: 0.7564 - val_loss: 0.5248 - val_accuracy: 0.7604

Epoch 23/30

79/79 [=====] - 11s 138ms/step - loss: 0.5560 - accuracy: 0.7532 - val_loss: 0.5437 - val_accuracy: 0.7500

Epoch 24/30

79/79 [=====] - 11s 138ms/step - loss: 0.5514 - accuracy: 0.7516 - val_loss: 0.5345 - val_accuracy: 0.7361

Epoch 25/30

79/79 [=====] - 13s 167ms/step - loss: 0.5331 - accuracy: 0.7596 - val_loss: 0.5125 - val_accuracy: 0.7535

Epoch 26/30

79/79 [=====] - 11s 137ms/step - loss: 0.5666 - accuracy: 0.7349 - val_loss: 0.6057 - val_accuracy: 0.7361

Epoch 27/30

79/79 [=====] - 11s 136ms/step - loss: 0.5564 - accuracy: 0.7484 - val_loss: 0.5253 - val_accuracy: 0.7465

Epoch 28/30

79/79 [=====] - 11s 141ms/step - loss: 0.5294 - accuracy: 0.7532 - val_loss: 0.5612 - val_accuracy: 0.7604

Epoch 29/30

79/79 [=====] - 11s 136ms/step - loss: 0.5549 - accuracy: 0.7428 - val_loss: 0.5233 - val_accuracy: 0.7778

Epoch 30/30

79/79 [=====] - 11s 138ms/step - loss: 0.5455 - accuracy: 0.7580 - val_loss: 0.5406 - val_accuracy: 0.7500

مرحله چهاردهم

ذخیره کردن مدل



```
#saving model
```

```
model.save("/content/gdrive/My Drive/Kaggle/result_Humerus.h5")
```

مرحله پانزدهم



```
import json  
his = history.history  
with open("/content/gdrive/My Drive/Kaggle/history_Humerus.json", 'w') as file:  
    json.dump(his, file)
```

پارامتر history که هیستوری کامل از زمان train را نشان میدهد.